

AdaBoost 检测结合 SOM 的自动人脸识别方法

叶剑锋, 王化明

(南京航空航天大学 机电学院, 江苏 南京 210016)

摘 要: 针对当前许多人脸识别算法需要人工干预以及剪裁图像尺寸与运行速度不平衡的问题, 提出一种利用自组织网络的自动人脸识别方法。利用 AdaBoost 人脸检测算法定位来获取人脸图像, 并转化为相同尺寸的灰度图像; 将图像的训练子集用于训练自组织映射(SOM)分类器, 再利用相似性度量完成分类。在 Libor Spacek 数据集、扩展 Yale B 数据集和 FERET 数据集上进行验证, 结果显示提出的方法实现了全自动处理, 三个测试集的识别率均在 97.00% 左右, 均优于对比算法。

关键词: 人脸识别; AdaBoost 算法; 分类器; 自组织映射; 分级模型; 相似性度量; 自动处理

DOI: 10.11990/jheu.201608036

网络出版地址: <http://www.cnki.net/kcms/detail/23.1390.u.20171025.1642.020.html>

中图分类号: TP391 **文献标志码:** A **文章编号:** 1006-7043(2018)01-0129-06

An automatic face recognition method using AdaBoost detection and SOM

YE Jianfeng, WANG Huaming

(College of Mechanical and Electrical Engineering, Nanjing University of Aeronautics and Astronautics, Nanjing 210016, China)

Abstract: Many existing face recognition algorithms require manual intervention, and an imbalance exists between the size of the cropped image and the running speed. An automatic face recognition method based on self-organizing map (SOM) was proposed to address these issues. First, AdaBoost face detection algorithm was used to obtain a face image, which was then converted into a grayscale image with the same size. Subsequently, the training subset of the image was used for training SOM classifier. Finally, the similarity measurement was used to complete the classification. The effectiveness of the proposed algorithm was verified by the results of the tests carried out for Libor Spacek dataset, extended Yale B dataset, and FERET dataset. Compared with the LDA, LDP, and WSR algorithm, the proposed method achieves fully automated processing. The recognition rates of the three test sets were all 97.00%.

Keywords: face recognition; AdaBoost algorithm; classifier; self-organizing map; hierarchical model; similarity measurement; automated processing

人脸识别^[1]是生物识别技术的一个重要分支,对警用以及涉及国家安全的军事用途很重要,如人脸识别技术可以用来支持像智能眼镜、可穿戴人脸识别系统对人的识别^[2-3]。近年,虽然人脸识别技术有了很大进步,但仍然面临着许多挑战,如处理低质量的图像或照明不充分的图像。理想情况下,人脸识别系统应解决以下问题:处理非受控环境、含有多种族面孔的数据库和老化效应^[4]等。

人脸识别方法中,比较具代表性的有主成分分

析(principal component analysis, PCA)^[5]、线性成分分析(linear discriminant analysis, LDA)^[6]、独立主成分分析(independent component analysis, ICA)^[7]等。这些方法在解决带有光照、姿态、表情和场景变化的人脸识别问题时,效果不理想。也有很多人脸识别依赖 Gabor 变换,文献[8]将 Gabor 变换的人脸识别分为分析和综合两类。分析方法如基于图和基于非图的增强方法,即使用最优 Gabor 参数的 Gabor 算法以及 AdaBoost 算法^[8];综合方法包括下采样 Gabor、LDA、PCA、局部二值模式等。

文献[9]使用基于高阶局部衍生变化的衍生模式(local derivative pattern, LDP)来编码方向图的特征,包括 FERET、CAS-PEAL、CMU-PIE、扩展 Yale B

收稿日期: 2016-08-18.

网络出版日期: 2017-10-25.

基金项目: 国家自然科学基金项目(61363066).

作者简介: 叶剑锋(1984-),男,讲师,博士研究生;

王化明(1973-),男,教授,博士生导师.

通信作者: 叶剑锋, E-mail: 18690318152@163.com.

和 FRGC 的数据库,识别率在 78.9% ~ 97.9% 变化。然而,较高的识别率只能在手动调整和裁剪的帮助下实现。

文献[10]提出了结合快速离散曲波变换(fast discrete curvelet transform, FDCT)和二维主成分分析方法(2 dimensional-principal component analysis, 2D-PCA)的人脸识别方法(FDCT-2DPCA)。其中,FDCT 作为特征提取器,2D-PCA 可来降低计算复杂度,但要求是二维正脸或近似正脸的需求。

由于深度学习可以比较好地描述图像的局部和全局特性,文献[11]使用深度学习(deep learning, DL)算法进行训练,一定程度上提高了面部表情识别率。然而,该方法训练耗时较长。

文献[12]通过使用图像预处理技术,即分辨率变换、直方图均衡和边缘检测来增强脸部识别,提出了一种改进正则化超分辨率重建方法(improved regularization super resolution reconstruction, IRSRR)来进行特征选择,超分辨率(super resolution, SR)算法可从一个或多个低分辨率图像重建高分辨率图像,但 SR 算法重建的效果很大程度上取决于较多假设前提,即使基于学习的 SR 算法构建字典也比较困难,而且运行时间较长。由于 SR 技术的应用,文献[13]提出了一种基于高频小波子带字典的方法,该方法利用超分辨率来增强人脸识别。然而,该方法除了使用非常大的图像之外,还依赖于手工校准和裁剪。

综上,许多传统的方法都不能完全实现自动化处理,且有些方法运行效率不高。为此,提出一种 AdaBoost 人脸检测结合自组织映射(self-organizing map, SOM)的自动人脸识别方法(AdaBoost-SOM)。

1 AdaBoost 结合 SOM 的自动人脸识别算法

AdaBoost-SOM 方法由三个主要部分组成:预处理、训练器和测试部分。

预处理:使用 AdaBoost 人脸检测算法对图像中的人脸进行检测,如果人脸存在,则进行自动裁剪。输出通常是不同大小的人脸。因此,预处理器的下一个子步骤是调整检测到的人脸大小到相同大小。然后,所有图像都转换为灰度图像,并分成两个子集:训练子集和测试子集;

训练:图像的训练子集用于训练自组织映射(self-organizing map, SOM)分类器,其中,每个人都有一定数目类的分级模型,所有人的模型都将用于测试在测试子集中的图像。

测试:使用在先前步骤中创建的分级模型,对图

像的测试子集进行识别测试。构建特征值,利用相似性度量确定测试图像的相似性,与测试图像相关值最高的子类确定为输出。

1.1 预处理器

预处理器使用 Matlab 实现以下任务:

人脸检测:输入图像的人脸可定位在该图像的任意位置。使用 AdaBoost 人脸检测算法来定位和获取输入图像中的人脸,并进行人脸剪裁^[14]。

减小图像尺寸:训练和测试需要图像中包含人脸的分区,上一步的输出是原始图像的一部分,因此,需要重新调整尺寸到标准的人脸大小。

转换为灰度图像:为了便于处理,在灰度图像上进行处理。

一个成功的人脸识别系统的三个主要特点是高识别率、高计算性能和实现简单。其中预处理器的目的是生成需要的人脸图像。

1.2 自组织映射

在神经网络中,有两种方法可以训练网络。第一种是监督训练,即每个输入图像都有一个目标,通过网络学习改变其权重,表示输入和输出图像之间的关系。第二种是无监督训练,在没有先验信息的情况下,改变目标权重,对输入图像进行分类^[15]。

AdaBoost-SOM 方法是基于无监督神经网络学习,神经元通过竞争来激活,以便在任何时候都只有一个神经元激活^[15]。通过这种激活过程,神经元进行了自我组织。因此,这种网络又称为“自组织映射”。

自组织映射的主要目标是自适应地执行一个非线性变换,或者把数据映射到一维或二维空间,因此,网络必须基于以下几点进行训练^[15]:

- 1) 初始化:所有神经元的连接权重向量 $\{w_j, j \in [1, M], M \text{ 是神经元数}\}$ 随机初始化。
- 2) 采样:对输入图形 x 进行采样。
- 3) 匹配:确定获胜神经元 $i(x)$,获胜神经元是权重向量最接近输入图像的神经元。
- 4) 更新:获胜神经元的权重向量及其相邻神经元的权重向量通过以下公式进行更新:

$$w_j = w_j + \eta h_{ji(x)}(x - w_j) \quad (1)$$

式中: η 是学习率, h 是高斯邻域函数,其定义如下

$$h_{ji(x)} = \exp\left(-\frac{d_{ji}^2}{2\sigma^2}\right) \quad (2)$$

式中: d_{ji} 是获胜神经元和神经元 j 之间的横向距离, σ 是高斯邻域函数的宽度。

- 5) 迭代:返回步骤2)并重复进行,直到权重不再变化。

1.3 训练器

假设 N 代表数据库中人的总数, P_i 代表第 i 个

人可用的图像数量。若所有的人都有相同数量的图像,则

$$P_1 = P_2 = \cdots = P_N = P \quad (3)$$

在数据库中可用的图像总数为 $TI_DB = N \times P$, 具有 TI_DB 幅图像的数据集可分为两个子集: 训练子集和测试子集, 训练子集的大小为

$$T_r = f \times TI_DB \quad (4)$$

式中: f 直在训练中使用的图片部分, 范围在 0 ~ 100% 变动, 其余的图像用于测试, 其中测试子集的大小是:

$$T_s = (1 - f) \times TI_DB \quad (5)$$

设定 $f = 65\%$, 即 65% 的图像用于训练, 35% 的图像用于测试。提出的利用 SOM 的人脸识别系统采用 K-类的方法。因此, 训练器为每个人建立一些参考图像类 R , R 指每个人的参考图像数, 其中 $R \leq T_r$, T_r 指训练集中的图片总数, 对应的测试集中的图片总数用 T_s 表示, 类的总数量是 $TC = N \times R$ 。

接着, 讨论每个参考图像的构造, 使用 SOM 把每个人的 T_r 图像分成 R 类。经验表明: R 的最优值为 4, 分类后, 只需要保证每个类至少有一个图像。第 k 类的参考图像是属于第 k 类的所有图像的平均图, 即参考图像 k 的 $Pixel_{ij}$ 值, 其中 $i, j \in [1, A]$, 可定义为

$$Pixel_{ij}(R_k) = \frac{\sum_{l=1}^m Pixel_{ij}(Picture_l)}{m} \quad (6)$$

式中: R_k 表示第 k 类的参考图像, 是离线构造的。

得到参考图像 R_k 后, 利用优化程序对每个参考图像进行简单优化, 令 $d_j \in \mathbf{R}^m$ 为 R_k 的第 j 个原子项 $j \in [1, M]$ 假设 $x_{j*} \in \mathbf{R}^{1 \times N}$ 的行向量为 R_k 的第 j 行, 固定 R_k 和所有原子项, 构建下面的优化问题:

$$\min_{d_j} H(d_j) = \left\| Y - \sum_{k \neq j} d_k x_{k*} - d_j x_{j*} \right\|_F^2 + \lambda \left\{ \sum_{i=1}^N x_{ji}^2 \|y_i - d_i\|_2^2 + \sum_{i=1}^N \sum_{k \neq 1}^K [x_{ki}^2 \|y_i - d_k\|_2^2] \right\} \quad (7)$$

设置 $E = Y - \sum_{k \neq j} d_k x_{k*}$, 消除不相关项, 可简化为

$$\min_{d_j} H(d_j) = T_r \{ (E - d_j x_{j*}) (E - d_j x_{j*})^T \} + \lambda \sum_{i=1}^N [x_{ji}^2 (y_i - d_j)^T (y_i - d_j)] \quad (8)$$

由于 $H(d_j)$ 为凸, $H(d_j)$ 关于 d_j 的梯度设为零, 得到最优解:

$$d_j = \frac{1}{(1 + \lambda)(x_{j*} x_{j*}^T)} (E x_{j*}^T + \lambda Y \alpha) \quad (9)$$

$\alpha = [x_{j1}^2, x_{j2}^2, \cdots, x_{jN}^2]^T \in \mathbf{R}^N$ 是 x_{j*}^T 中项的平方值列向量, 由此, 完成了对参考图像 R_k 的优化。

1.4 测试

给出一张测试图像, 测试阶段需要测试每一个参考图像, 并通过下式计算测试图像和参考图像之间的特征值 φ :

$$\varphi = \frac{\frac{1}{A} \sum_{i=1}^A (I_R(i) - m_{I_R})(I_T(i) - m_{I_T})}{\sigma_{I_R} \sigma_{I_T}} \quad (10)$$

式中: $I_R(i)$ 和 $I_T(i)$ 是在字典顺序向量中分别代表参考图像和测试图像的像素点 i 的灰度值, A 为图像中像素的数量, m_{I_R} , m_{I_T} , σ_{I_R} 和 σ_{I_T} 分别是参考图像和测试图像的平均值和标准差。

对某个对象而言, 利用相似性度量, 选择 φ 最大的类作为识别结果, 测试阶段的操作算法如下所示:

输入: 测试图像

数据库中 $N \times R$ 的参考图像

输出: 人的识别输出(人的指数)

初始化决策 = 1;

$\varphi_{\text{Highest}} = 0$;

for Person_{*i*}, $1 \leq i \leq N$, Do:

$\varphi_{\text{Accredited}}(\text{Person}_i) = 0$;

for Class_{*k*}, $1 \leq k \leq R$, Do:

计算 φ_k ;

if $\varphi_k > \varphi_{\text{Accredited}}(\text{Person}_i)$, then

$\varphi_{\text{Accredited}}(\text{Person}_i) = \varphi_k$;

end if

end for

if $\varphi_{\text{Accredited}}(\text{Person}_i) = \varphi_{\text{Highest}}$, then

$\varphi_{\text{Highest}} = \varphi_{\text{Accredited}}(\text{Person}_i)$

结果 Decision = i ;

end if

end for

返回结果 Decision

2 实验结果与分析

实验使用如下配置的计算机: 英特尔酷睿 II 双核 CPU 2.1 GHz 主频, 4 GB RAM, 64 位微软 Windows7 操作系统, 编程工具为 Matlab 11。

2.1 测试度量

使用结构相似度量(structure similarity measures, SSIM)进行结果测试。SSIM 是用来衡量两张图像之间相似度的一个指标, 比较局部图像的像素强度, 比较符合人眼的评价标准, 两幅图像(x 和 y)的相似性定义如下:

$$SSIM(x, y) = \frac{(2\mu_x \mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (11)$$

式中: 常量 C_1 和 C_2 满足 $C_1 = (K_1 L)^2$, $C_2 = (K_2 L)^2$,

K_1 是一个小的常数 (0.01) K_2 也是一个小的常数 (0.03) L 是像素值的动态范围 (0 ~ 255) μ_x 是图像 x 的平均值 μ_y 是图像 y 的平均值 σ_x^2 是图像 x 的方差 σ_y^2 是图像 y 的方差 σ_{xy} 是图像 x 和 y 之间的协方差。SSIM 的值在 0 ~ 1 变化, SSIM 的值越大表示相似程度越高。

2.2 Libor Spacek 人脸图像数据库

使用 Libor Spacek 人脸图像数据库^[16]来评价 AdaBoost-SOM。Libor Spacek 数据库包含四个数据库,这四个数据库包含不同年龄不同种族的 395 位女性和男性的图像,分别是: Faces94、Faces95、Faces96 和 Grimace。这些类别从最容易识别到最难识别进行分类,Face94 是最容易识别的, Grimace 是最难识别的。该数据库中的每个人都具有 20 张不同姿势和不同的面部表情的图像,总共有 7 900 张图像,且光照条件也不同,使用数据库中 362 个人的 7 240 张图像。AdaBoost-SOM 的目的是提出一个全自动人脸识别系统,避免任何人工裁剪。AdaBoost 算法能够检测和剪裁的图像总数是 362 个人的 7 240 张图像。实验中,方形预处理图片区域为 625 像素,数据库中包含 362 名对象,每个人图片数量为 20 张,训练数据中使用的图片部分比例占比为 0.65,训练集中共有 4 706 张图片,测试集中共有 2 534 张图片,系统中分类为 1 448 类。

如表 1 所示 $f=0.65$ 对一个人而言,13 张图像用于训练,剩下的 7 张图像用于测试,表 1 所示为 7 个测试图像的结果。在训练阶段中使用的图像是随机选取的,经过人脸检测和剪裁后的 13 张图像的尺寸不同,捕获的平均面部尺寸大约是 100×100 像素,图像大小重置为 25×25 像素后按相应顺序排列的图像,图 1 所示为 4 阶 SOM 类的图像。



图 1 计算获得的 4 张 SOM 图像

Fig. 1 Calculate the four SOM images obtained

表 1 7 个测试图像的 SSIM 结果

Table 1 SSIM results for 7 test images

图像名称	SSIM
sandm. 3. jpg	0.954 9
sandm. 4. jpg	0.960 4
sandm. 5. jpg	0.951 9
sandm. 6. jpg	0.984 8
sandm. 7. jpg	0.987 9
sandm. 8. jpg	0.982 2
sandm. 9. jpg	0.972 8

测试阶段所使用的图像总数为 2 534, AdaBoost-SOM 成功识别了 2 457 张人脸,测试所有图像的总时间为 28 733.72 s,即平均需要约 11.3 s 来识别 2 534 幅图像之间的任一图像。这个时间与其他系统差不多。实现的识别率在 97.00% ~ 99.50% 变化。图 2 所示为提出的利用 SOM 的人脸识别方法使用从 0.001 ~ 1 变化的错误接受率所实现的验证率,从图中可以看出,所实现的验证率在 83% ~ 100%。




图 2 得到的 ROC 值

Fig. 2 The resulting ROC value

2.3 与其他算法的比较

一般情况,优秀的人脸识别算法应具有以下特点^[10]:

- 1) 全自动: 不需要人为干预;
- 2) 工作在一个由大量的个体组成的大型数据库中: 用于测试人脸识别方法的图像数量越大,该方法越好;
- 3) 高识别率和高验证率;
- 4) 速度快: 快速识别人脸,预处理、训练和测试应具有最小的延迟;
- 5) 图像尺寸和运行速度的平衡: 图像的尺寸越大,正确识别人的概率就越大。然而图像尺寸越大,识别速度就越慢,需要一个平衡。

2.3.1 Libor Spacek 数据库上的比较

FDCT-2DPCA^[10]、DL^[11]、IRSRR^[12]及 AdaBoost-SOM 都使用了 Libor Spacek 数据库中的 Face94 部分进行实验,识别结果如表 2 所示。从表 2 可以看出,FDCT-2DPCA 和 IRSRR 在 Face94 上的识别率分别为 94.04%、95.01%,而 AdaBoost-SOM 识别率可高达 97.05%,略低于 DL,表明 AdaBoost-SOM 与目前较为先进的深度学习算法所得识别率相当。从时间方面可以看出,DL 需要 23.94 s,IRSRR 需要 16.30 s,而 AdaBoost-SOM 仅需 11.32 s,略多于 FDCT-2DPCA,利用深度学习算法进行训练耗时较多,IRSRR 采用超分辨率重建,也在一定程度上增加了耗时,而 FDCT-2DPCA 使用 2DPCA 进行特征提取,降低了计算复杂度,故耗时较短。综合识别率和执行时间可见,AdaBoost-SOM 更具优越性。

表 2 Libor Spacek 数据库的 Face94 实验结果比较
Table 2 Comparison of Face94 experiment results of libor spacek database

算法	训练	测试	尺寸	时间/s	识别率/%	人工调整/剪裁
FDCT-2DPCA	10 个体 × 15	10 个体 × 5	180 × 200	10.03	94.04	是
DL	100 个体 × 13	100 个体 × 7	180 × 200	23.94	97.15	否
IRSRR	20 个体 × 15	20 个体 × 5	180 × 200	16.30	95.01	否
AdaBoost-SOM	362 个体 × 13	362 个体 × 7	25 × 25	11.32	97.05	否

2.3.2 扩展 Yale B 数据库上的比较

扩展 Yale B 数据库^[17]是耶鲁大学人脸识别 Yale 数据库的一个扩展库,包含 16 128 幅图像,28 岁以下 9 种姿态,64 种光照条件,图 3 为示例图像。LDP^[9]算法使用了一些高分辨率的图像来测试该方法,有 38 个个体被识别,每个个体有 9 个图像。每个图像都有 84 × 96 像素的分辨率。该算法在扩展 Yale B 数据库上的识别率略高于 AdaBoost-SOM,但所有用于测试和训练系统的图像都经过手动对齐和裁剪,LDA^[6]算法和文献[13]的加权稀疏表达算法(weighted sparse representation,WSR)都是相似情况,它们的个体总数都较少,只有 38 个,训练图像总数都多于 AdaBoost-SOM,且都对图像进行了

手动对准和裁剪,从而达到高分辨率。故这些算法能取得较高的识别率,但在运行时间上明显多于 AdaBoost-SOM。




图 3 扩展 Yale B 数据库中人脸图像实例

Fig. 3 Extends the face image instance in the Yale B database

表 3 扩展 Yale B 数据库上的实验结果比较
Table 3 Extended comparison of experimental results on the Yale B database

算法	训练	测试	尺寸	时间/s	识别率/%	人工调整/剪裁
LDA	38 个体 × 15	38 个体 × 49	84 × 96	19.2	96.21	是
LDP	38 个体 × 16	38 个体 × 25	84 × 96	22.6	97.51	是
WSR	38 个体 × 22	38 个体 × 36	84 × 96	27.5	97.72	是
AdaBoost-SOM	362 个体 × 13	362 个体 × 7	25 × 25	10.7	96.93	否

2.3.3 FERET 数据库上的比较

FERET 数据库^[18]是美国国防部发起的人脸识别工程,包括一个通用的人脸库以及测试标准,同一个人包括不同表情、光照、姿态和年龄的照片,包括 1 000 多人数万张照片,并且一直在不同扩充,FERET 中的人脸图像示例如图 4 所示。LDP^[9]在 FERET 数据库上测试一张图像的时间为 0.54 s,这个时间看起来很小。然而,它是一对一图像匹配的测量时间,即如果在测试阶段包含所有的测试图像,那么这一时间将成倍增加。图像大小为 88 × 88 像素,这比 AdaBoost-SOM 中的图像尺寸大得多,该算法的识别率也只有 90.15%,WSR 取得的识别率

为 91.73%,而 AdaBoost-SOM 实现的识别率最高,可高达 96.59%。




图 4 FERET 数据库中的人脸图像示例

Fig. 4 An example of a face image in the FERET database

表 4 FERET 数据库上的实验结果比较
Table 4 Comparison of experimental results on FERET database

算法	训练	测试	尺寸	时间/s	识别率/%	人工调整/剪裁
LDP	1 541	1 203	88 × 88	0.54	90.15	是
WSR	2 522	1 513	88 × 88	1.25	91.73	是
AdaBoost-SOM	3 549	1 613	25 × 25	2.7	96.59	否

4 结论

1) 使用 AdaBoost 人脸检测算法可有效定位和获取输入图像中的人脸;

2) 在不需要人为干预的情况下, AdaBoost-SOM 可取得较高的识别率和运行效率;

3) 使用 SOM 迭代训练, 即使在小尺寸图像中, 也可以实现优越的识别结果。

参考文献:

- [1] 崔鹏, 张汝波. 半监督系数选择法的人脸识别[J]. 哈尔滨工程大学学报, 2012, 33(7): 855-861.
CUI Peng, ZHANG Rubo. A semi-supervised coefficient selection method for face recognition [J]. Journal of Harbin Engineering University, 2012, 33(7): 855-861.
- [2] 李月龙, 靳彦, 汪剑鸣, 等. 人脸特征点提取方法综述[J]. 计算机学报, 2016, 39(7): 1356-1374.
Li Yue-long, JIN Yan, WANG Jian-ming, et al. Face feature points extraction: a review [J]. Chinese journal of computers, 2016, 39(7): 1356-1374.
- [3] WRIGHT J, YANG A Y, GANESH A, et al. Robust face recognition via sparse representation [J]. IEEE transactions on pattern analysis & machine intelligence, 2009, 31(2): 210-227.
- [4] 唐守军, 吴洪武. 基于 Snake 模型和协作表示分类的鲁棒人脸识别方法[J]. 湘潭大学自然科学学报, 2016, 38(2): 104-108.
TANG Shoujun, WU Hongwu. A robust face recognition method based on snake model and collaborative representation classification [J]. Natural Science Journal of Xiangtan University, 2016, 38(2): 104-108.
- [5] 王亚星, 齐林, 郭新, 等. 基于稀疏 PCA 的多阶次分数阶傅里叶变换域特征人脸识别[J]. 计算机应用研究, 2016, 33(4): 1253-1257.
WANG Yaxing, QI Lin, GUO Xin, et al. Fusion of complementary discrete fractional Fourier features extracted through sparse PCA in generalized frequency domains for face recognition [J]. Application research of computers, 2016, 33(4): 1253-1257.
- [6] VINAY A, SHEKHAR V S, MURTHY K N B, et al. Performance study of LDA and KFA for gabor based face recognition system [J]. Procedia computer science, 2015, 57(3): 960-969.
- [7] PEDDIGARI V R, SRINIVASA P, KUMAR R. Enhanced ICA based face recognition using histogram equalization and mirror image superposition [C]//2015 IEEE International Conference on consumer electronics. [S. l.], 2015: 625-628.
- [8] 张娟, 詹永照, 毛启容, 等. 基于 Gabor 小波和稀疏表示的人脸表情识别[J]. 计算机工程, 2012, 38(6): 207-209.
ZHANG Juan, ZHAN Yongzhao, MAO Qirong, et al. Facial expression recognition based on gabor wavelet and sparse representation [J]. Computer engineering, 2012, 38(6): 207-209.
- [9] ZHANG B C, GAO Y S, ZHAO S Q, et al. Local derivative pattern versus local binary pattern: face recognition with high-order local pattern descriptor [J]. IEEE transactions on image processing, 2010, 19(2): 533-544.
- [10] ZHAO J, ZHOU Z, CAO F. Human face recognition based on ensemble of polyharmonic extreme learning machine [J]. Neural computing & applications, 2013, 24(6): 1317-1326.
- [11] ZHAO X, SHI X, ZHANG S. Facial expression recognition via deep learning [J]. Iete technical review, 2015, 32(5): 347-355.
- [12] 程建. 基于改进正则化超分辨率重建方法的人脸识别研究[D]. 西安: 西安电子科技大学, 2014.
CHENG Jian. Research on face recognition based on improved regularization super-resolution reconstruction [D]. Xi'an: Xidian University, 2014.
- [13] LU C Y, MIN H, GUI J, et al. Face recognition via weighted sparse representation [J]. Journal of visual communication and image representation, 2013, 24(2): 111-116.
- [14] SCHROFF F, KALENICHENKO D, PHILBIN J. FaceNet: A unified embedding for face recognition and clustering [C]// Computer Vision and Pattern Recognition. IEEE: NY, USA, 2015: 815-823.
- [15] CHOWDHURY M I H, ALAM F I. A probabilistic approach to support self-organizing map (SOM) driven facial expression recognition [C]// International Conference on Computer and Information Technology. IEEE: NY, USA, 2014: 210-216.
- [16] BHASKAR B, ANUSHREE P S, SHREE S D, et al. Quantitative analysis of kernel principal components and kernel fishers based face recognition algorithms using hybrid gaborlets [J]. Procedia computer science, 2015, 58(8): 342-347.
- [17] VIPPARATHI S K, MURALA S, GONDE A B, et al. Local directional mask maximum edge patterns for image retrieval and face recognition [J]. Iet computer vision, 2016, 10(3): 182-192.
- [18] 卢桂馥, 林忠, 金忠. 基于核化图嵌入的最佳鉴别分析与人脸识别[J]. 软件学报, 2011, 22(7): 1561-1570.
LU Guifu, LIN Zhong, JIN Zhong. Optimal discriminant analysis based on kernel extension of graph embedding and face recognition [J]. Journal of software, 2011, 22(7): 1561-1570.

本文引用格式:

叶剑锋, 王化明. AdaBoost 检测结合 SOM 的自动人脸识别方法[J]. 哈尔滨工程大学学报, 2018, 39(1): 129-134.
YE Jianfeng, WANG Huaming. An automatic face recognition method using adaboost detection and SOM [J]. Journal of Harbin Engineering University, 2018, 39(1): 129-134.