

P300 Speller 中基于权值重采样的 ABSVM 字符识别方法研究

蔡宏志^{1,2}, 孙长城¹, 许敏鹏¹, 明 东¹, 万柏坤¹, 刘志朋², 殷 涛²

(1. 天津大学精密仪器与光电子工程学院, 天津 300072; 2. 中国医学科学院生物医学工程研究所, 天津 300192)

摘 要: P300 Speller 是脑-机接口中重要的信息交互方式, 由于其诱发的脑电特征信噪比较低与训练样本量庞大等问题, 常规的线性识别算法和支持向量机等非线性识别算法难以获得理想的识别效率. 本文引入了一种基于权值样本重采样过程的 Adaptive Boosting SVM (ABSVM) 方法, 在大样本集上利用 AdaBoost 重采样方法建立一系列小样本子集, 在其上训练支持向量机并将其集成后进行识别. 对 6 位受试者 P300 Speller 字符辨识实验的脑电特征识别结果发现, 该方法能够显著提高字符识别效率, 在合并使用 5 次重复刺激特征的情况下字符识别准确率达到 97.5%. 使用国际脑机接口竞赛数据库数据进一步验证, 在合并使用 5 次重复刺激特征的情况下该方法识别正确率较竞赛报告的最优方法提高 7.35%, 最大信息传输速率的提高达到 48.9%. 研究结果表明, ABSVM 方法能够有效提高 P300 Speller 的识别效率和信息传输速率, 值得进一步研究和发展.

关键词: 自适应增强支持向量机; 事件相关电位; 脑-机接口; 权值重采样

中图分类号: TP18 **文献标识码:** A **文章编号:** 0372-2112 (2011) 11-2534-06

Study of ABSVM Character Recognition Method Based on Weighted Resampling in P300 Speller

QI Hong-zhi^{1,2}, SUN Chang-cheng¹, XU Min-peng¹, MING Dong¹, WAN Bai-kun¹, LIU Zhi-peng², YIN Tao²

(1. School of Precision Instruments and Optoelectronics Engineering, Tianjin University, Tianjin 300072, China;

2. Institute of Biomedical Engineering, Chinese Academy of Medical Sciences, Tianjin 300192, China)

Abstract: P300 Speller is an important information transforming method in Brain-Computer Interface. However, because the signal-to-noise ratio is comparably low and the size of training sample set is too large, the recognition efficiency in P300 Speller is not ideal by using popular linear recognition method or non linear methods such as Support Vector Machine. This paper introduces a novel method based on Adaptive Boosting SVM using weighted resampling process. We use AdaBoost resampling method to construct a series of little size training sample sub sets on the large integer set and then train the SVMs on these sub sets, finally run the recognition by combining these SVM's output. Using 6 subjects' EEG features from P300 Speller character identifying experiment we find that this method improves character identifying accuracy significantly. We achieve a character identifying accuracy of 97.5% on combining 5 repetitive stimulus features. A further evaluation using international BCI Competition dataset has proved that this method achieves a 7.35% enhancement in character identifying accuracy and a 48.9% enhancement in information transforming velocity on combining 5 repetitive stimulus features. This study demonstrated that ABSVM has the ability of improve recognition accuracy and information transforming velocity in P300 Speller and it is worthy of a further study and development.

Key words: adaptive boosting support vector machine (ABSVM); event related potential (ERP); brain computer interface (BCI); weighted resampling

1 引言

P300 Speller 是脑-机接口 (Brain-Computer Interface) 中一种重要的信息交互方案, 它可以在人脑和计算机之

间建立一种不依赖于外周神经和肌肉系统的字符输出通路^[1]. P300 Speller 的目的是直接通过思维脑电操作电脑进行字符输出, 有别于传统的手指击键字符输出方式^[2]. P300 Speller 一个显而易见的 application 前景是可帮助运

收稿日期: 2010-09-17; 修回日期: 2011-05-23

基金项目: 国家自然科学基金 (No. 30970875, No. 90920015, No. 60501005); 国家自然科学基金委-英国爱丁堡皇家学会联合研究项目 (No. 30910494); “十一五”国家高技术研究发展 863 计划 (No. 2007AA04Z236); 天津市科技支撑计划重点项目生物医学工程专项 (No. 07ZCKFSF01300); 国际科技合作专项 (No. 08ZCCHHZ00300)

动功能丧失但大脑意识健全的截瘫患者一定程度上恢复信息交流能力,对于提高截瘫患者的生活质量、减轻其家庭和社会负担具有重要的意义^[3].因此基于该模式的脑机接口系统发展迅速,目前已在正常人^[3]和肌萎缩性侧索硬化残疾患者身上得到初步的成功运用^[4,5].

P300 Speller 方案中以字符行/列的随机闪烁建立视觉刺激序列,通过置于使用者头皮的表面电极采集脑电信息,检测脑电事件相关电位(Event Related Potential, ERP)中的 P300 成份来辨识出受试者关注的字符,进而使人脑在不使用任何肢体实际动作的情况下能够完成向计算机输出自主信息的目的^[2].

上述过程的关键环节是采用高效的识别算法在大量背景刺激(即非靶刺激)中识别出含有 P300 成份的靶刺激,进而确定包含有目标字符的闪烁行/列.由于 P300 成份本身幅度很低,且信号中混杂有高幅度的自发脑电 EEG 信号,线性分类算法的识别效果很不理想,因此许多更复杂的非线性分类算法如支持向量机(Support Vector Machine, SVM)等被陆续引入以提高识别效率^[3].然而 P300 Speller 的识别分类器训练时所面对的刺激样本集非常庞大,这主要是因为:(1)稳定诱发 P300 成份的生理学机制要求 P300 Speller 的视觉刺激序列中必须含有数量远多于靶刺激的非靶刺激;(2)为补偿 P300 幅度较小的问题识别过程必须要合并多次重复靶刺激的特征;(3)在线系统的实际操作中会不断获得新的刺激样本,识别算法应适当关注新样本以提高识别稳定性,这就使得训练样本集得到不断扩展.SVM 等复杂的非线性识别算法在大数据集上的训练运算较大,耗时较长,非常不利于样本集的更新和算法的优化,导致识别效率的提升受到很大的限制.

针对这一问题,本文设计了 Adaptive boosting (AdaBoost)方法增强的支持向量机识别算法,在大样本集上采用重采样方法构建多个小样本集,将小样本上的支持向量机分类器组进行集成判别,使得识别算法的学习过程可以在多个小样本集上进行,该方法不但可以有效提高识别准确率,而且可以显著降低大样本集上的运算负荷,有利于快速识别,为建立高效在线判别算法奠定了良好的基础.

2 基于 Adaptive Boosting SVM (ABSVM) 的 P300 Speller 字符识别算法

2.1 Adaptive Boosting (AdaBoost)

Freund 和 Schapire 提出的 Adaptive Boosting 算法,其基本思想是对于错分类的样本,提升其在分类器训练中权重,通过一系列的迭代过程让分类器更“注意”这些被错分的样本,从而提升分类器的泛化能力^[6]. Adaboost 在给定训练样本集 $X = [x_1, x_2, \dots, x_n]^T$ 和类别标

识 $Y = [y_1, y_2, \dots, y_n]^T$ 情况下(n 为总的样本数),首先初始化样本权重分布函数,

$$D_1(i) = 1/n, i = 1, 2, \dots, n \quad (1)$$

然后进行事先设定的 T 个迭代过程,其中每迭代一次生成一个基分类器 $h_t: X \rightarrow R$,其带权训练误差为

$$\epsilon_t = \sum_i D_t(i) I(y_i \neq h_t(x_i)) \quad (2)$$

Adaboost 要求每个基分类器至少是一个弱分类器,因此若 $\epsilon_t < 0.5$ 则接受该 h_t ,然后进行下一次迭代,此时首先选择更新系数

$$\alpha_t = \frac{1}{2} \ln \frac{1 - \epsilon_t}{\epsilon_t} \quad (3)$$

然后对整个样本集中的样本更新权重

$$D_{t+1}(i) = \frac{D_t(i) \exp(-\alpha_t y_i h_t(x_i))}{Z_t} \quad (4)$$

这里 Z_t 是归一化常数,用以保证总的权值和为 1,即

$$\sum_i D_{t+1}(i) = 1 \quad (5)$$

然后进行下一次迭代,得到下一个基于新的样本权重分布情况下的基分类器 h_{t+1} .迭代 T 次后,最终得到的 Adaboost 集成分类器的判别函数输出为

$$J(x) = \sum_{t=1}^T \alpha_t J_t(x) \quad (6)$$

对 x 的预测标识则为

$$H(x) = \text{sign} \left[\sum_{t=1}^T \alpha_t h_t(x) \right] \quad (7)$$

AdaBoost 算法中,在 T 个基分类器的分类错误率都满足 $\epsilon_t < 0.5$ 的情况下,令 $\gamma_t = 0.5 - \epsilon_t$,则其分类错误率上界理论上为 $\frac{1}{n} \left| \{i: H(x_i) \neq y_i\} \right| \leq \prod_{t=1}^T \sqrt{1 - 4\gamma_t^2}$

$\leq \exp(-2 \sum_{t=1}^T \gamma_t^2)$,也即是随着基分类器数目 T 的增加,集成分类错误率呈指数级下降.因此,理论上只要每个基分类器都是弱分类器,AdaBoost 就能提升其分类正确率,而且研究发现当 T 非常大时 AdaBoost 很少发生过学习现象^[7,8].

2.2 重采样过程

对于基分类器的带权训练有两种方式,一种是直接将权值加入代价函数中,直接优化带权重代价函数;另一种是使用基于样本权值的重采样方法获得训练样本子集,子集中高权重的样本含量高于低权重的样本含量,从而使使得在训练子集上的分类器更重视高权重的样本.尽管两种方法的优劣目前尚无定论,但已有研究表明,在不平衡样本集上重采样过程可以获得较带权训练更好的 boosting 效果^[9].如前所述,由于 P300 Speller 的训练样本集很大,采用直接带权训练的方法时使得训练效率很低,本文采用权值重采样方法在 Adap-

tive Boosting 的迭代阶段构建小训练样本集,可以有效降低训练时的运算量.基于重采样的 Adaboost 在第 t 次迭代过程中首先根据总的样本权重分布 D_t 选取 m 个样本 ($m \ll n$),构成 t 次迭代的训练样本子集 $X^t = [x_1^t, x_2^t, \dots, x_m^t]^T$ 和样本标识子集 $Y^t = [y_1^t, y_2^t, \dots, y_m^t]^T$,在 X^t 和 Y^t 上训练第 t 个基分类器 h_t .采用重采样过程的另一个好处是,在大样本集上采用重采样方法构建小的训练样本子集并训练基分类器时,基分类器的错误率可以在整个样本集上进行估计,由于训练子集远小于整个样本集,因此错误率的估计不会受到分类器过学习问题的干扰,可以获得稳健的错误率估计.

2.3 支持向量机与 ABSVM

支持向量机是 Vapnik 等人根据统计学习理论提出的一种机器学习方法,它以结构风险最小化准则为理论基础,通过适当地选择函数子集及其子集中的判别函数,使学习机器的实际风险达到最小,保证了通过有限训练样本得到的小误差分类器,对独立测试集的分类误差仍然较小.支持向量机中所建立的最优分类面要求不仅能将两类样本正确分开,而且同时要求分类间隔达到最大.支持向量机首先通过内积函数定义的非线性变换将输入空间变换到一个高维空间,然后在这个高维空间中求解线性最优分类面^[10,11].

本文采用线性内积核函数形式建立支持向量机,在样本子集 X^t 上建立的线性核 SVM 的决策函数为

$$J_i = \sum_{i=1}^m \beta_i - \frac{1}{2} \sum_{i,j=1}^m \beta_i \beta_j y_i y_j \langle x_i, x_j \rangle \quad (8)$$

这里 $x_i \in X^t$, β_i 为各样本对应的拉格朗日系数, SVM 训练过程得到的 β_i 仅有部分不为 0, 这些 β_i 所对应的样本既是所谓的支持向量^[11]. 式(6)和式(8)即为 ABSVM 的决策函数表达式. 采用权值重采样方法构建 ABSVM 的每个训练子集仅含有少量的样本数,从而充分利用了 SVM 在小样本集上的泛化能力.

2.4 重复刺激条件下的字符识别算法与信息传输速率

P300 Speller 的字符识别的特点是在一组 6 个待选样本(行/列)中识别出 1 个目标样本(行/列),因此其识别过程不是模式识别中经典的 0-1 判别模式.在此情况下,分类器的决策函数有可能在一组 6 个样本(行/列)中判别出 0 个或多个靶刺激,因此对于靶刺激的判别不但要考虑决策值的符号,还需考虑其在一组样本中的相对大小,本文中每组内决策函数输出值最大的一个样本(行/列)判断为靶刺激,即

$$\text{tar}^j = \arg \max_i \{ J^j(x_i), i = 1, 2, \dots, 6 \} \quad (9)$$

这里 i 表示一组内 6 个样本的序号, j 表示样本组的序号^[12].

因此, P300 Speller 的算法评价中一般采用字符识别正确率代替样本识别正确率.由于脑电信号的信噪比较低,通过单次任务刺激往往很难得到可靠的识别效果, P300 Speller 对于每个字符的识别任务往往进行多个重复刺激组的诱发,这时,首先使用训练完成的分类器对每个行/列刺激样本计算决策值,然后将同一字符任务不同刺激组中对应于相同行/列刺激的决策值取平均,再利用公式 9 选择出靶刺激,进而判断出目标字符. P300 Speller 的信息传输速率采用单位时间内传递信息的 bit 数表示,一个任务刺激的 bit 数 B 与识别正确率 p 和任务刺激所能对应的命令模式总数 N 有关, P300 Speller 中每个字符可以认为是一个待选择的命令模式,其总的命令模式数为 36,

$$B = \log_2 N + p * \log_2 p + (1 - p) * \log_2 [(1 - p)/(N - 1)] \quad (10)$$

其信息传输速率则为 B 乘以单位时间内任务刺激的呈现个数^[13].

3 P300 Speller 实验与诱发脑电特征

P300 Speller 实验的任务刺激模式如图 1 所示,在计算机屏幕上显示 6×6 的虚拟字符矩阵,字符矩阵的行或列被随机高亮度闪烁,每个行/列的闪烁可视为一个视觉刺激,包含有目标字符的行/列闪烁构成一个靶刺激,可在头皮脑电中诱发出 P300 成份.屏幕上矩阵的 12 个行和列的闪烁组成一个刺激组(stimulus block),每个刺激组中行和列的闪烁次序是随机出现但不重复的,也即一个刺激组中含有且仅含有一个行靶刺激和一个列靶刺激.

每个任务开始前 3s 在计算机屏幕中央给出要求注意的目标字符,然后屏幕中央显示出字符矩阵并开始进行随机的行/列闪烁,每个行/列的闪烁时间为 100ms,两次闪烁中间矩阵有 75ms 的不闪烁间隔期,任务过程中在矩阵上方也始终显示出该目标字符.每个任务进行 15 个刺激组的重复刺激,也即每个字符共包含 180 个闪烁刺激,其中含有的靶刺激个数为 30 个.实验中每进行 8 个字符的任务后受试者休息 2 分钟,共采集 6 位受试者,每个受试者共进行 80 个字符的识别任务实验.刺激实验和脑电信号采集均在 Neuroscan 的 Scan4.3 系统上进行,采样频率 1000Hz,经过 0.1-40Hz 的带通滤波处理.脑电采集使用系统自带的 64 导电极帽,其中含有 4 导肌电与眼电导联(CB1、CB2、VEO、HEO),因此脑电信号采集导联共 60 导,其安放位置按照国际标准 10-20 系统放置,如图 2 所示.

图 3 所示为四个中线导联 Fz、Cz、Pz、Oz 处在单次刺激和多次刺激叠加平均之后的脑电波形,其中实线表示靶刺激下的 ERP 波形,虚线则为非靶刺激下的波

形. 图中 $t = 0$ 处为闪烁刺激起始时刻, 因此图中所示为刺激呈现和完成后 900ms 的波形. 由图 3 中可见单次刺激下靶刺激与非靶刺激的诱发脑电波形差别不明显, 而多次叠加平均后靶刺激与非靶刺激下的脑电波形则有着明显的差异. 因此, 分类算法须合并多个重复刺激的特征方可获得较好的靶刺激识别效果, 进而可靠的“翻译”出受试者关注的目标字符. 但合并过多的重复刺激则会使得信息传输效率降低, 所以高效的识别算法必须同时考虑上述两方面的因素.

4 识别结果与信息传输效率

4.1 本文实验数据的识别效果与信息传输效率

以闪烁刺激后 700ms 的波形数据作为每个脑电导联上的基本特征, 将 60 导特征首尾联接后作为识别特征向量. 对 P300 Speller 而言, 每个闪烁刺激的诱发脑电波形均构成一个样本, 分类器的任务既是在 12 个一组的行列闪烁中选择出一个行闪烁和一个列闪烁, 相当于在 12 个样本中识别出两个目标样本. P300 Speller 实验中一般对每个字符进行 15 个刺激组的重复诱发, 这样每个字符任务共产生 $12 \times 15 = 180$ 个样本, 本文实验中对每个受试者进行了 80 个字符的任务刺激, 共产生

的样本数量为 $180 \times 80 = 9600$. 本文采用 10 折交叉验证来估计识别正确率, 每次采用的训练样本集为其中 72 个字符的 8640 个样本, 测试集则为剩余的 8 个字符 (共 960 个样本), 识别正确率为 10 折交叉验证的平均值.

AdaBoost 迭代过程中训练样本子集大小的确定需折衷考虑运算速度和识别效率, 训练子集过小则识别效率下降较多, 过大则运算速度过慢, 经过多次实验本文算法中选择训练样本子集大小为 400 个样本点, 在这个尺度的样本集上 SVM 训练可以迅速完成并保证较高的识别效率. 6 位受试者的字符刺激识别结果如图所示, 图 4 中左侧六个图为每位受试者的识别正确率随 Adaboost 迭代刺激次数的增加而变化的曲线, 最右侧图为 6 位受试者的平均曲线, 每个图中 rep1 ~ rep5 表示采用 1 次 ~ 5 次重复刺激组的特征进行识别的结果. 由图 4 中可见随 Adaboost 迭代次数的增加, 字符识别准确率明显上升, 使用 5 次重复刺激的特征进行合并判别时, 识别正确率可达到 0.975 ± 0.0224 , 且此时 ABSVM 可在迭代次数很少 ($T < 20$) 的情况下得到平稳输出. 对于部分受试者来说, 仅使用一次刺激的情况下也可以获得较为满意的识别效果 (二位受试者可达到 0.9 以上). 但由于脑电特征可分性较大的个体差异和不同的采集条件影响, 单次刺激下的识别效率差别较大 (方差为 0.2318). 如受试者 6 的单次识别效率较低, 原因在于该受试者进行脑电任务实验时的头皮电阻较高 ($> 20k\Omega$), 所采集脑电信号的信噪比受到较大的影响.

为与 P300 Speller 中常规的 SVM 算法识别结果进行比较, 本文分别采用单一的线性核函数支持向量机 (LinearSVM) 和径向基核函数支持向量机 (RBF SVM) 建立分类器进行识别和对比分析, 单一 SVM 分类器建立是直接对所有训练样本进行学习和优化的结果. 三种方法识别结果的对比如图 5 所示, LinearSVM 与 RBF SVM 的识别结果相差不大, 可见在 P300 Speller 训练样本集较大的情况下, 核函数的选择对于识别结果的影响不显著. ABSVM 在识别正确率上高于 LinearSVM 和 RBF SVM, 这一趋势在采用较少的重复刺激特征的情况下更明显, 而在重复刺激特征较多的情况下, 三种方法的识别效率相差较小.

在采用 5 次重复刺激的情况下, 三种识别方法的信息传输速率如表 1 所示, 可见采用 ABSVM 进行识别可获得更高的信息传输速率. 常规 SVM 算法在整个样本集上进行训练的耗时约为 $10^3 \sim 10^4$ s, 而 ABSVM 的训

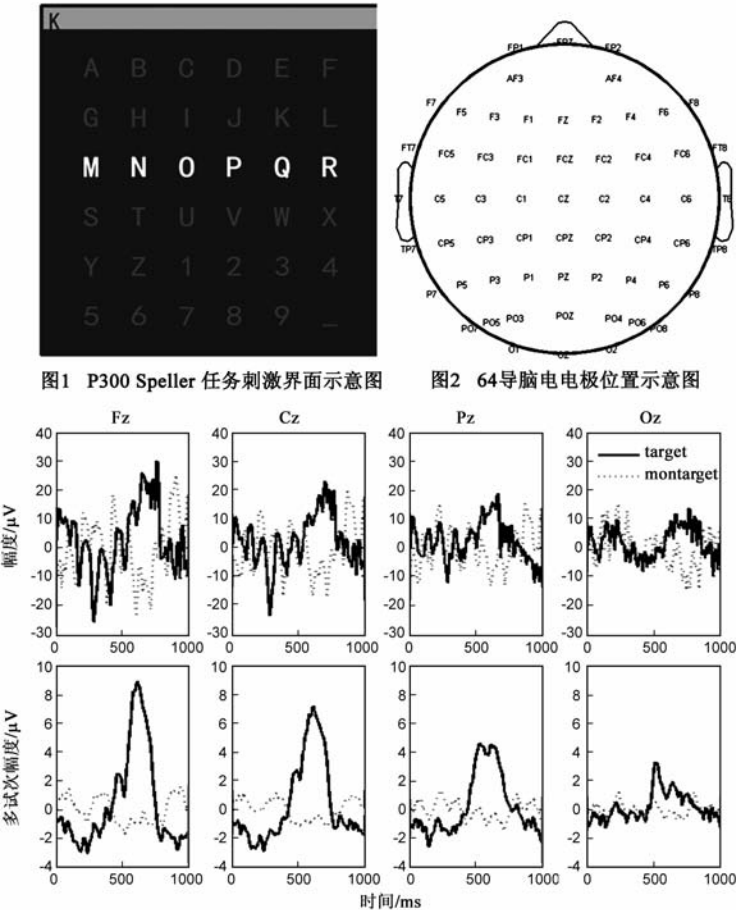


图3 4个中线导联Fz、Cz、Pz、Oz处在靶刺激和非靶刺激下的ERP波形




图2 64导脑电电极位置示意图

图1 P300 Speller 任务刺激界面示意图

练耗时为 10^2 s 左右. 训练 SVM 模型需要求解凸二次优化问题 (QP 问题), 其计算复杂度可认为正比于训练样本数 n 的三次方 ($O(n^3)$, 本文实验中 $n = 8640$). 而 ABSVM 算法中每个 SVM 模型仅在 400 个点的训练集上完成, 100 次迭代过程总的训练时间约为 $100 \times O(400^3) \ll O(8640^3)$. 因此相对于常规 SVM 算法, ABSVM 在训练集较为庞大的情况下极大的降低了算法的训练时间, 使得算法更易优化或根据数据集的更新情况进行及时调整.

4.2 公开数据集上的识别效果

为进一步评价 ABSVM 方法的有效性, 采用国际脑机接口竞赛数据库 (BCI Competition III) 中两组 P300 Speller 数据测试 (<http://www.bbc.de/competition/>

iii/)^[14]. 公开数据集中 P300 Speller 实验的设置基本与本文实验设置相同, 脑电采集导联为 64 导, 处理时采用闪烁刺激后 700ms 波形特征按照 64 导联首尾相接作为识别特征向量. 由于 BCI 竞赛的目的之一是考查各类算法的鲁棒性和抗噪声干扰能力, 因此竞赛数据库中提供的脑电数据含有较大的噪声和干扰, 使得算法的识别正确率较低. 最优识别算法由 Alain Rakotomamonjy 和 Vincent Guigue 提供, 该算法是目前公认的处理效果最优的 P300 Speller 识别算法. 最优算法的识别正确率如表 2 所示, 其在采用 15 次重复刺激的情况下可以达到 96.5% 的正确率, 高于其它方法 6% 以上 (次优方法正确率为 90.5%), 而该方法在仅采用 5 次重复刺激情况下可以获得 73.5% 的正确率, 高于其它方法 14% 以上 (次优方法正确率为 59.5%)^[15].

表 1 三种识别算法的信息传输率

重复刺激次数	信息传输率(bit/min)		
	LinearSVM	RBFSVM	ABSM
1	53.5	58.9	66.9
2	39.2	38.4	44.3
3	29.2	28.6	33.9
4	25.3	24.9	27.1
5	21.1	21.2	22.3

本文用 ABSVM 方法进行识别时采用如 4.1 相同的训练样本子集设置, 在竞赛数据库的训练样本集 15300 个样本中 (每个受试者 85 个字符的刺激任务) 以权重采样方法选取 400 个样本作为 SVM 训练子集, 采用 AdaBoost 方法进行 100 次迭代训练 ABSVM 模型, 在测试数据集 (每个受试者 100 个字符的刺激任务) 上进行识别. ABSVM 方法的识别正确率有明显提高, 如表 2 所示, 在 15 次和 5 次重复刺激条件下识别正确率分别达到




图4 subject1...subject6图为6位受试者使用ABSMV进行字符识别的正确率曲线,average 图为6位受试者正确率的平均曲线;其中rep1~rep5分别表示合并采用1~5次重复刺激特征时的识别结果

97.3%和 78.9% (相对于竞赛最优算法在相同条件下 96.5%和 73.5% 的识别正确率分别提高了 0.8%和 5.4%). 图中可见当重复刺激数量较少的情况下, ABSVM 识别正确率的提高更为显著. 由于重复刺激数量较少意味着信号特征中的噪声含量较大, 这也从一个侧面说明了 ABSVM 方法具有更强的鲁棒性和抗干扰能力.




图5 采用3种识别方法获得识别正确率对比, 其中横坐标表示合并采用重复刺激的个数

表 2 对国际脑机接口竞赛数据库的测试结果, 与竞赛最优方法的对比

重复刺激次数	竞赛最优方法		ABSM	
	识别正确率 (%)	信息传输率 (bit/min)	识别正确率 (%)	信息传输率 (bit/min)
1	25.5	15.1	36.8	28.0
2	42.5	17.7	54.1	26.0
3	57	18.8	64.1	22.7
4	64	17.0	69.5	19.4
5	73.5	17.0	78.9	19.1
10	87	11.3	92.2	12.5
13	95	10.2	95.4	10.3
15	96.5	9.1	97.3	9.2

另外, 由于 BCI 的信息传输效率与识别率和靶刺激频率均相关, 当重复刺激数量过多时, 虽然识别正确率

可以得到提高,但并不会提升信息传输速率.由表可见,最高的信息传输速率一般出现在采用较少重复刺激的情况下,也即是 BCI 识别算法的关键是采用尽量少的重复刺激获得尽量高的识别效果.比较 ABSVM 方法与 BCICompetition III 最优方法所获得的最高信息传输速率,ABSVM 提高了 9.2 bit/minute,提高幅度达到 48.9%,表明该方法更适合于建立高速 P300 Speller 系统.


5 结论与讨论

本文针对 P300 Speller 训练集庞大、特征信号信噪比较低的问题设计了一种基于 Adaptive Boosting 和 SVM 的字符识别方法,通过对大样本集进行重采样构建一系列样本数量很小的样本子集,在样本子集上训练和优化 SVM 算法,从而大幅度降低了训练时间并获得了更好的识别效率.通过对实验数据和国际脑机接口数据库处理的结果对比表明,ABSVM 方法可有效提高识别效率,进而获得更高的信息传输速率.本文研究表明基于权值重采样小样本集序列上的 Adaptive Boosting SVM 方法适用于大样本集的脑电特征识别,值得进一步发展和研究.

参考文献

- [1] Wolpaw JR, Birbaumer N, et al. Brain-computer interface technology: a review of the first international meeting [J]. IEEE Trans Rehabil. Eng., 2000, 8(2): 222 – 225.
- [2] Farwell LA, Donchin E. Talking off the top of your head: Toward a mental prosthesis utilizing event-related brain potentials [J]. Electroenceph clin Neurophysiol 1988, 70(6): 510 – 523.
- [3] Allison BZ, et al. Brain-computer interface systems: progress and prospects [J]. Expert Rev Med Devices, 2007, 4(4): 463 – 74.
- [4] 闫相国, 郑崇勋. 用核学习算法的意识任务特征提取与分类 [J]. 电子学报, 2004, 32(10): 1749 – 1753.
Yan Xiangguo, Zheng Chongxun. Classifications of EEG during mental tasks by kernel learning algorithms [J]. Acta Electronica Sinica, 2004, 32(10): 1749 – 1753. (in Chinese)
- [5] Serby H, Yom-Tov E, et al. An improved P300-based brain-computer interface [J]. IEEE Trans Neural Syst Rehabil Eng., 2005, 13(1): 89 – 98.
- [6] Sellers EW, Donchin E. A P300-based brain-computer interface: Initial tests by ALS patients [J]. Clin Neurophysiol, 2006, 117(3): 538 – 548.
- [7] Freund Y, Schapire R. A decision-theoretic generalization of on-line learning and an application to boosting [A]. In Proceedings EuroCOLT' 94: European Conference on Computational Learning Theory [C]. Athens, Greece, LNCS. 1994.
- [8] 李凯, 黄厚宽. 一种提高神经网络集成差异性的学习方法 [J]. 电子学报, 2005, 33(8): 1387 – 1390.
Li Kai, Huang Houkuan. An approach to improving diversity of neural network ensemble [J]. Acta Electronica Sinica, 2005, 33(8): 1387 – 1390. (in Chinese)
- [9] Ratsch G, Onoda T, Müller KR. Soft margins for adaBoost [J]. Machine Learning, 2001, 42(3): 287 – 320.
- [10] Freund Y, Schapire RE. A decision-theoretic generalization of on-line learning and an application to boosting [J]. Journal of Computer and System Sciences, 1997, 55(1): 119 – 139.
- [11] Seiffert C, Khoshgoftaar TM, et al. A napolitano, resampling or reweighting: a comparison of boosting implementations [A]. 20th IEEE International Conference on Tools with Artificial Intelligence [C]. Dayton, Ohio, USA, 2008. 445 – 451.
- [12] Vapnik VN. The Nature of Statistical Learning Theory [M]. NY: Springer-Verlag, 1995. 35 – 77.
- [13] 王国胜, 钟义信. 支持向量机的若干新进展 [J]. 电子学报, 2001, 29(10): 1397 – 1400.
Wang Guosheng, Zhong Yixin. Some new developments on support vector machine [J]. Acta Electronica Sinica, 2001, 29(10): 1397 – 1400. (in Chinese)
- [14] Cristianini N, et al. An Introduction to Support Vector Machines [M]. London: Cambridge University Press, 1999. 27 – 60.
- [15] Krusienski DJ, Sellers EW, McFarland DJ, Vaughan TM, Wolpaw JR. Toward enhanced P300 speller performance [J]. J Neurosci Methods 2008, 167(1): 15 – 21.
- [16] Wolpaw JR, Ramoser H, et al. EEG-based communication: improved accuracy by response verification [J]. IEEE Trans on Rehab. Eng., 1998, 6(3): 326 – 333.
- [17] Blankertz B, Mueller KR, et al. The BCI competition iii: Validating alternative approaches to actual BCI problems [J]. IEEE Trans Neural Syst. Rehabil. Eng., 2006, 14(2): 153 – 159.
- [18] Rakotomamonjy A, Guigue V. BCI competition III: dataset II - ensemble of SVMs for BCI P300 speller [J]. IEEE Trans Biomed Eng, 2008, 55(3): 1147 – 1154.

作者简介



蔡宏志 男, 天津大学精密仪器与光电子工程学院生物医学工程系讲师, 工学博士, 主要研究领域为神经与康复工程, 研究方向包括脑机接口, 生物医学信号处理, 脑电信号分析, 生物特征识别等.

E-mail: qhz@tju.edu.cn

明 东(通信作者) 男, 博士, 副教授, 博士生导师, 天津市生物医学检测技术与仪器重点实验室副主任, 天津大学神经工程与康复实验室主任. 2002 ~ 2003 年, 香港大学李嘉诚医学院矫形与创伤外科系助理研究员; 2005 ~ 2006 年, 英国苏格兰 Dundee 大学工程与物理科学学院访问学者. 主要从事神经工程、康复工程等领域的研究工作.

E-mail: richardming@tju.edu.cn